

יום אחד של מדידה ותיקון מול הפרודקשן. "לפני" = ריצת העומס של 10:12, "אחרי" = 10:39 והלאה. מה שלא נמדד — כתוב.

\$0.003

לכל קטע TTS

מדויק, לכל קריאה

0

מדיה שאובדת

תור + reaper · קריסה: PASS

×6

hero-image

9.0s → 1.5s · 493 → 136MB

×2.3

ב-30 unit-lesson

17.0s → 7.4s p50

שלוש התשובות


- 1השרת לא הגבול: ראוט DB עולה CPU 12ms; מופע web אחד מחזיק מאות ילדים. הגבול הוא מכסות ספקים ופולינג.
- 2הצינור הכבד (אודיו, תמונות, וידאו) יצא מהשרת לתור עם worker. עבודה שנופלת חוזרת לבד, ואומת בהריגה.
- 3הכסף נספר מעכשיו לכל קריאה: ספק, מודל, מטרה, שיעור, ילד, עלות. 40 שורות כבר בטבלה, כולן מדויקות.

מה נמצא, בסדר חומרה


ממצא	מה	השפעה	מצב
חסום event loop	72 קריאות DB סינכרוניות בראוטים async	~3 בקשות/ש' לכל התהליך	תוקן
לפתיחה 40 signed URLs	קריאה ל-Storage לכל קטע ותמונה	unit-lesson 17s, audio 5.5s	תוקן
ייצור בתוך הבקשה	נוצרו בבקשה, ×30 במקביל i-audio hero	נשרפה TTS מכסת, 493MB	תוקן
לקוח Supabase HTTP/2 יחידתי	קריס ב-30 sync + threads: 3.5 בלבד,	סריאליזציה של DB	תוקן
עבודות רקע בשרת	ריסטארט = מדיה אבודה בשקט	שיעורים אילמים	תוקן
פולינג 3 × 1.5s לולאות	160 בקשות/דקה לילד, מגביל 60	72% מקבלים 429	בקוד
מכסת Gemini TTS	429 עם worker אחד	אין אודיו	OpenRouter
בטור TTS	14-19 קטעים × 6s	שיעור 170-185s	פתוח

פירוט לכל API בעמודים 3-5, הצינור בעמוד 6, צווארי בקבוק בעמוד 7, מפת השינויים בעמוד 9.

לפני



אחרי



מה זה שינה

רכיב	לפני	אחרי	ראיה
בקשה	תופסת thread לאורך כל קריאת DB	awaited המודל, ב-threadpool DB	8 בקשות עם auth של 1.1s → 8s
מדיה	בתהליך השרת, אובדת בריסטארט	תור עם dedupe, heartbeat, reaper, עדיפות באמצע → הושלם SIGKILL	
Storage	לכל קובץ לכל בקשה signed URL	batch + לשעה cache	40 קריאות → 0-1
ייצור	בתוך הבקשה, בלי dedupe	בתור או תחת נעילה	30 → 1
TTS	ישיר, מכסה Gemini	אותו מודל, OpenRouter	אין 0.003\$/קטע; 429
מדדים	סיכומים בלבד	request_log, service_metrics, ai_calls	לכל בקשה, תהליך, קריאה

ראוט	סוג	מחכה ל	לפני	אחרי	מה השתנה
GET /learning-lessons/.../units	sync	DB	—	861ms	בלי שינוי
POST /tutor/active-lesson-state	sync	DB	1025ms	512ms	לקוח HTTP
GET /tutor/shared-transition/{t}	sync	DB	341ms	517ms	רעש
POST /tutor/unit-lesson/hero-image	async	DB, Gemini image	9035ms	1513ms	נעילה + cache
POST /tutor/unit-lesson/visuals	sync	DB, Storage	6740ms	3204ms	cache signed URLs
POST /tutor/unit-lesson/audio	sync	DB (היה: TTS)	5.5s	תור	לא מייצר בבקשה
POST /tutor/unit-lesson	async	תור, DB, OpenAI	17040ms	7434ms	loop, cache, batch
POST /tutor/lesson-intro	sync	תור, DB	—	2305ms	תור
POST ../regenerate-transition	async	תור, DB	—	—	threadpool
POST /tutor/reset-unit-lesson	sync	DB	—	—	—
POST /tutor/lesson	async	OpenAI	—	—	threadpool, הקשר
POST /tutor/chat	async	OpenAI gpt-4o-mini	—	4.5-6s × 5	threadpool, הקשר
POST /tutor/tts	async	Gemini TTS	500 (מכסה)	OpenRouter ספק + הקשר	
POST /tutor/homework-analyze	async	OpenAI vision	—	—	threadpool, הקשר
POST /tutor/homework-session	sync	DB	—	—	—
POST /tutor/homework-coach	async	OpenAI	—	—	threadpool, הקשר
POST /tutor/homework-turn	async	OpenAI	—	—	threadpool, הקשר
POST /curriculum/chat	async	OpenAI	—	—	threadpool, הקשר
POST /curriculum/approve	sync	DB	—	—	—
GET /	async	—	—	—	health

"—" = לא נמדד בעומס (ראוטי מודל עולים כסף בכל קריאה; DB-בלבד לא רלוונטי). "threadpool" = קריאות DB ירדו מה-event loop.
"הקשר" = הראוט מסמן purpose/kid/lesson לכל קריאת מודל שהוא עושה (ai_calls).

מה הטבלה אומרת

- ראוטי 27-81: DB בקשות/שנייה, CPU 12ms כל אחת. הזמן הוא רשת ל-150ms (~ Supabase לסיבוב).
- ראוטי המדיה היו האסון: signed URL לכל קובץ, וייצור בתוך הבקשה. שניהם נעלמו.
- ראוטי המודל לא תופסים thread; הזמן שלהם הוא המודל. התקרה שלהם: מכסות OpenAI.
- עם ילדים שונים — לא נמדד. progress ב-30 במקביל של אותו ילד: תחרות על שורות עדיון 7.4 unit-lesson.

POST /api/tutor/unit-lesson

מה	פתיחת יחידת שיעור: מה-cache, או ייצור עם gpt-5.6-sol (70-92) ואז מדיה
מחכה ל	signed URLs, בייצור, 3 הכנסות לתור OpenAI, progress, ילד, שיעור, auth
לפני	מדיה בתוך השרת; loop-DB; לבקשה signed URLs ב-30 במקביל, כולן יחד; 40s 17.0s
אחרי	מדיה בתור עם עדיפות 10; batch-DB; חתימה batch 1; 7.4s
תיקון	main.py: dispatch_media_job, signed_url_cached, add_signed_urls (batch), async_db_helpers
צוואר בקבוק עכשיו	כתיבות progress של אותו ילד; JSON גדול בתשובה; לא נמדד עם ילדים שונים

POST /api/tutor/unit-lesson/audio

מה	הפרונט שואל עד שהאודיו מוכן; מחזיר lesson_audio עם URLs חתומים
מחכה ל	(חתימה) Storage, ילד, שיעור, auth
לפני	אם לא מוכן — ייצר TTS בתוך הבקשה, +100 ש', 30× במקביל בלי 27×500 dedupe, מכסה נשרפה
אחרי	מכניס עבודת unit_lesson_audio לתור (dedupe) ומחזיר "generating" מיד; חתימה ב-batch
תיקון	main.py generate_unit_lesson_audio (ייצור הוחלף ב)
צוואר בקבוק עכשיו	לא נמדד מול הפרוד אחרי התיקון (אופליין: 10 במקביל, 0.6s)

POST /api/tutor/unit-lesson/hero-image

מה	תמונת הפתיחה של השיעור; מייצר אם חסרה
מחכה ל	(בייצור) Storage, Gemini image, ילד, שיעור, auth
לפני	30 בקשות = 30 ייצורים במקביל: p50 9.0s, p90 20s, 493MB, 121% CPU
אחרי	ראשון hero מייצר worker-ייצור אחד תחת נעילה; ה p50 1.5s, 18 req/s, 136MB
תיקון	קודם main.py: generation_lock, signed_url_cached; media job: hero
צוואר בקבוק עכשיו	ייצור ~3.5s ל-Gemini כשחסר

POST /api/tutor/unit-lesson/visuals

מה	רשימת התמונות המוכנות של השיעור; הפרונט שואל עד שכולן קיימות
מחכה ל	21× Storage, ילד, שיעור, auth
לפני	לכל תמונה לכל בקשה signed URL: 3.5 req/s, 6.7s
אחרי	לשעה cache: 11 req/s, 3.2s
תיקון	main.py create_lesson_media_signed_url → signed_url_cached
צוואר בקבוק עכשיו	ראוט סינכרוני; req/s ב-11 CPU גדול לכל בקשה (55% JSON)

POST /api/tutor/chat

מה	הודעת צ'אט של הילד → תשובה מובנית של gpt-4o-mini
מחכה ל	usage/כתיבות ששן, OpenAI, ילד, זיכרון, 7 הודעות היסטוריה, auth
לפני	ילד, היסטוריה, (ששן): 8 קריאות, auth) loop-DB
אחרי	5 במקביל: 4.5-6s p50 (זמן המודל), 0 שגיאות; DB ב-threadpool; עלות לכל קריאה
תיקון	tools/async_db_helpers.py, ai_context("chat")
צוואר בקבוק עכשיו	זמן המודל: 4.5-6s לתשובה מלאה. streaming יביא מילה ראשונה ב-1s

POST /api/tutor/tts

מה	(חי למשפט של המורה (מחוץ לשיעור המוקלט TTS
מחכה ל	מחכה ל, Gemini TTS (async), auth
לפני	5/5 נכשלו: 429 מכסת DB; Gemini; על ה-loop
אחרי	TTS_PROVIDER=openrouter: 4-8 וקול, \$0.003/נרשם ב-ai_calls
תיקון	main.py tutor_tts: OpenRouter (openrouter_tts_pcm_async)
צוואר בקבוק עכשיו	latency 4-8 ששל הספק: 27, (מ-8 1) סולפעים

POST /api/tutor/lesson · homework-coach · homework-turn · curriculum/chat

מה	שיחות מובנות מול OpenAI (שיעור, שיעורי בית, בניית תכנית)
מחכה ל	auth, DB, OpenAI
לפני	DB בלי מעקב עלות/מודל; loop-על ה-DB
אחרי	purpose (lesson_chat / homework / curriculum) כל קריאה נרשמת עם; DB ב-threadpool
תיקון	tools/async_db_helpers.py, ai_context(...)
צוואר בקבוק עכשיו	לא נמדד בעומס (כל קריאה עולה כסף). התקרה: מכסות OpenAI

POST /api/tutor/homework-analyze

מה	ניתוח צילום שיעורי בית (vision)
מחכה ל	auth, vision, Storage, ילד, OpenAI
לפני	DB loop-על ה-
אחרי	threadpool + הקשר עלות
תיקון	tools/async_db_helpers.py
צוואר בקבוק עכשיו	הורדת הקובץ מ-Storage בתוך הבקשה; לא נמדד

POST /api/tutor/lesson-intro

מה	פתיח לשיעור; למנויים — סרטוני פתיחה אישיים (3, ~139 ש')
מחכה ל	auth, kid_personal_media, ילד, מנוי
לפני	ייצור וידאו ב-BackgroundTasks בשרת
אחרי	(fallback ב-30 במקביל; וידאו בתור בעדיפות 60 יש 2.3s)
תיקון	main.py: dispatch_media_job("kid_intro_videos")
צוואר בקבוק עכשיו	ראוט סינכרוני (CPU 66%); וידאו 46s לסרטון

units · active-lesson-state · shared-transition · reset · approve · homework-session/start

מה	ראוטי DB בלבד
מחכה ל	auth + שאלתה
לפני	—
אחרי	(Supabase-רשת ל) 0.3-1.0s p50, 12ms CPU לבקשה, 27-81 req/s
תיקון	Supabase pooled HTTP/1.1 לקוח
צוואר בקבוק עכשיו	סיבובי רשת: 2-4 לבקשה × ~Realtime/cache. 150ms יורידו

הצינור ברקע: אודיו, תמונות, וידאו

לפני: BackgroundTasks בשרת. אחרי: media_jobs + worker

מחזור חיים של עבודה

שלב	מה קורה
enqueue	הראוט מכניס שורה; dedupe על (סוג, שיעור) חי; עדיפות לפי סוג; בקשה דחופה מושכת קדימה
claim	worker attempts+1, started_at, לוקח את הדחופה ביותר, אטומי
heartbeat	כל 10-30 ש'; RSS נדגם כל 2 ש' ונשמר ב-metrics של העבודה
finish	duration_ms; אחרי 5 failed ניסיון, או 60s backoff עם pending או done
reaper	זה מה שהציל את בדיקת הקריסה. (או failed) pending → ש' 60-300 heartbeat בלי running

מה נמדד

שלב	מודל / מבנה	זמן	הערה
ייצור שיעור	gpt-5.6-sol	70-92 ש'	השרת ב-CPU 0-2%: המתנה
hero	gemini-3.1-flash-lite-image	3.2-5 ש'	ראשון בעבודה, לפני הכל
אודיו לשיעור	בטור 14-19 × TTS	105-236 ש'	6 ש' לקטע; 27 ש' לפעמים
תמונות	14-21 × 3.5-5 ש', 3 במקביל	30-60 ש'	ב-cache hit 4.7 ש'
סרטוני פתיחה	3 × 46~ ש'	139 ש'	פעם לילד
עבודת מדיה שלמה	(אודיו תמונות) + hero	169-184 ש'	שיא RSS 200-212MB

בדיקת הקריסה (13:26)

- 1 שיעור חדש נוצר (85 ש'), עבודת מדיה נתפסה. 20 ש' אחר כך: SIGKILL ל-worker. הספיק: 6, hero תמונות, 4 קטעי TTS.
- 2 (attempt 2) החזיר את העבודה reaper-חדש עלה. אחרי 60 ש' ה worker
- 3 ניסיון 2: hero מה-6, cache תמונות 8, cache hit תמונות + 14 קטעי TTS מחדש. 183 ש'. אודיו מוכן.
- 4 מה אבד: 4 קטעי (~\$0.013 TTS). אין cache לקטע — השיפור הבא. מה נחשף: "generating" תמיד נחשב תקוע (תוקן).

לפני / אחרי בצינור

מצב	לפני	אחרי	מצב
ריסטארט באמצע	מדיה אבודה בשקט, שיעור אילם	העבודה חוזרת ומושלמת	אומת
כישלון אודיו	נבלע; "done" בלי אודיו	העבודה נכשלת ורצה שוב; אודיו לא-מוכן = כישלון	אומת
סדר	אודיו חיכה 2:20 מאחורי וידאו: FIFO	עדיפויות + hero ראשון	אומת SQL
ניתוק/400/429 TTS	קריאה אחת מפילה הכל	ריטריי; Storage ריטריי על ניתוק בלבד	אומת
מכסה	חינמי, נגמרת Gemini	OpenRouter pay-as-you-go	אומת

צווארי בקבוק: מה נשאר, לפי סדר

מה עוצר אלפי משתמשים היום, עם הראיה והצעד

1 בטור בתוך עבודת מדיה TTS

ראיה: שיעור חדש = 170-185 ש' עד שיש אודיו; worker אחד = 20~ שיעורים/שעה
צעד: 4 קטעים במקביל: 40~ ש' לשיעור, פי 4 תפוקה. OpenRouter לא מגביל

2 פולינג הפרונט (בקוד, לא בדפדפן עדיין)

ראיה: 72% מבקשות ילד בשיעור חדש נחסמו; 34 req/s ל-50 ילדים
צעד: backoff נכנס ל-index.html; לבדוק בדפדפן; אופציה: Supabase Realtime

3 גדול JSON + תחרות שורות: unit-lesson

ראיה: 7.4s ב-30 של אותו ילד; CPU 55% ב-visuals
צעד: למדוד עם ילדים שונים; לצמצם את ה-audio + visuals בתשובה אחת

4 אודיו כל-או-כלום

ראיה: הפרונט מתחיל רק כשכל האודיו מוכן (~105 ש'); חלק 1 מוכן ב-50
צעד: כתיבה לפי חלקים + שינוי בפרונט: חצי מזמן ההמתנה

5 ספק חריג latency

ראיה: 27-29 OpenRouter TTS: ש' לפעמים (2 מ-90)
צעד: 90 timeout ש' קיים; ריטריי; במקביל מסתיר

6 מכסות OpenAI

ראיה: לא נבדק בעומס (5 במקביל עברו)
צעד: לבדוק RPM/TPM בחשבון; backoff על 429

7 יחיד worker

ראיה: עבודה יתומה של 236 ש' עיכבה שיעור חדש ב-162 ש'
צעד: 2 concurrency + ב-Render; זיכרון: 90MB + 110MB לעבודה

8 מחירים חסרים

ראיה: תמונות ווידאו נרשמים בלי עלות (unknown)
צעד: ai_costs_daily; AI_IMAGE_PRICES_JSON סופר

9 מגביל קצב בזיכרון

ראיה: לא מדויק עם 2 מופעים
צעד: Redis (יש קונטיינר) או טבלה

10 ללא cache לקטע TTS

ראיה: ריטריי/קריסה = כל הקטעים מחדש
צעד: לבדוק קיום segment_N.wav לפני ייצור

40

שורות ב-ai_calls כבר

כולן עם עלות מהספק

\$0.27

היום OpenRouter

90~ קריאות 3: TTS שיעורים + בדיקות

\$0.003

קטע TTS של 6 שניות

מדויק: ~165 טוקני פלט, OpenRouter

שיעור חדש אחד

מה	קריאות	עלות	מקור
אודיו, OpenRouter	14-19 קריאות	\$0.05-0.06	נמדד
אודיו, Gemini ישיר	אותן קריאות	~\$0.03-0.04 לפי M/\$10	הערכה
ייצור השיעור, gpt-5.6-sol	2-6 קריאות	\$30/\$5 למיליון; מעכשיו ב-ai_calls	הערכה
תמונות, flash-lite-image	14-21 + hero	אין מחיר בקוד — AI_IMAGE_PRICES_JSON	לא ידוע
סרטוני פתיחה	3 לילד	אין מחיר בקוד	לא ידוע
צ'אט, gpt-4o-mini	הודעה	~\$0.0003-0.001 לפי \$0.60/\$0.15	הערכה

איפה רואים

view	מה יש שם
ai_calls	שורה לכל קריאה: provider, model, purpose, kid, lesson, tokens, seconds, latency, cost, source
ai_costs_daily	יום × ספק × מודל × מטרה: קריאות, שגיאות, טוקנים, latency, עלות, כמה בלי מחיר
ai_costs_per_lesson	כמה עלה כל שיעור (מדיה לחוד)
ai_costs_per_kid	כמה עלה כל ילד ליום

לאלף ילדים

- המדיה לשיעור, לא לילד: כיתה של 150 יחידות ≈ \$9 אודיו + תמונות, פעם אחת.
- העלות המשתנה לילד: צ'אט, ~30 הודעות ביום ≈ 1.5 סנט ליום, ~\$0.45 לחודש. סרטוני פתיחה: פעם אחת, מחיר לא בקוד.
- אחרי יום עבודה אמיתי מחליף את כל ההערכות כאן במספרים ai_costs_daily

קובץ	מה	מצב
supabase/migrations/20260914_media_jobs.sql	RPC 5 + התור	רץ בפרוד
.../20260914_ops_metrics.sql	request_log, service_metrics, views, prune	רץ בפרוד
.../20260914_media_jobs_priority.sql	priority, claim לפי עדיפות, pull-forward	רץ בפרוד
.../20260914_ai_calls.sql (+ rollback)	ai_calls, 2 RPC, 3 views	רץ בפרוד
backend-ai-tutor-he/main.py	תור, cache, נעילות, ריטריי, ספקים, הקשר, loop	בקוד
backend-ai-tutor-he/worker.py	תהליך ה-worker: claim, heartbeat, reaper, מדדים, הקשר	בקוד
backend-ai-tutor-he/ops_metrics.py	ברקע request_log + service_metrics	בקוד
backend-ai-tutor-he/ai_costs.py	עטיפת הלקוחות, ai_calls, פתרון עלות מהספק	בקוד
he/workspace/index.html	טאב מוסתר, 7 לולאות, backoff, 429, iakidsPollSleep	בקוד
tools/ (e2e, load_api, tts_check)	בדיקות: מקצה לקצה, עומס, ילדים, TTS	בקוד
tools/async_db_helpers.py	קריאות DB ב-async → threadpool	בקוד
handoff_performace.md	כל הממצאים, המדידות והצעדים, כרונולוגית	בקוד

מה נשאר לפני קומיט

- 1 הפולינג החדש מהדפדפן האמיתי: לפתוח שיעור חדש ב-workspace ולראות ב-request_log_hourly שאין 429.
- 2 עם ילדים שונים (יש 4 בכיתה ה' בחשבון): להפריד תחרות שורות מעלות אמיתית unit-lesson.
- 3 ראוט audio מול הפרוד אחרי התיקון (אופליין עבר).
- 4 (משתני הסביבה החדשים (למטה + Background Worker שירות: Render).
- 5 ואז: TTS במקביל, אודיו הדרגתי, cache לקטע, Redis למגביל, מחירים לתמונות/וידאו.
- משתני סביבה חדשים: MEDIA_JOBS_MODE, WORKER_CONCURRENCY, AI_PROVIDER, TTS_PROVIDER, OPENROUTER_API_KEY, AI_PRICES_JSON, AI_IMAGE_PRICES_JSON, SUPABASE_HTTP_POOL, OPS_METRICS_ENABLED, AI_COSTS_ENABLED, MEDIA_JOB_MAX_ATTEMPTS.